

KernelSage 设计技术文档

项目	内容
高校	天津师范大学
赛题编号	proj18
赛题名称	面向小型操作系统的分析比对智能体系统设计
队伍名称	一定要以人类的身份赢啊
成员	鲍灿辉、石雅禛
指导老师	王毅
文档版本	v2.0
文档用途	初赛设计技术文档，配合 README、操作手册、演示视频、网站和开源仓库审查使用

目录

- [1. 比赛准备和调研](#)
 - [1.1 项目目标描述](#)
 - [1.2 赛题理解与评审场景](#)
 - [1.3 历史样本与开源资料调研](#)
 - [1.4 相关技术调研与路线取舍](#)
- [2. 系统框架和模块设计](#)
 - [2.1 总体架构](#)
 - [2.2 入口与任务调度层](#)
 - [2.3 数据采集与仓库画像层](#)
 - [2.4 历史样本选择与相似线索层](#)
 - [2.5 LLM 增强、报告审计与回退层](#)
 - [2.6 网站展示与部署层](#)
 - [2.7 核心数据结构与模块映射](#)
- [3. 开发计划](#)
 - [3.1 阶段一：MVP 仓库分析闭环](#)
 - [3.2 阶段二：LLM 可控接入和证据核验](#)
 - [3.3 阶段三：历史样本选择和代码相似线索](#)
 - [3.4 阶段四：样本扩展、网站发布和提交材料收敛](#)
 - [3.5 风险与回退计划](#)
- [4. 比赛过程中的重要进展](#)
 - [4.1 阶段时间线](#)
 - [4.2 从单仓库分析扩展为历史作品比对](#)

- [4.3 从 Top 3 对比扩展到 Top 5 对比](#)
- [4.4 历史基线库扩展到 141 个样本](#)
- [4.5 建立可公开访问的网站](#)
- [4.6 系统测试和质量验证](#)
- [5. 遇到的主要问题和解决方法](#)
 - [5.1 历史仓库来源复杂，部分仓库无法 clone](#)
 - [5.2 样本来源分级不清，容易造成获奖信息误用](#)
 - [5.3 关键字匹配容易误判 OS 机制](#)
 - [5.4 C++、unikernel、RTOS 等非典型内核覆盖不足](#)
 - [5.5 功能重合和代码相似边界不清](#)
 - [5.6 LLM 输出存在幻觉和越界判断风险](#)
 - [5.7 大样本库重复分析耗时](#)
 - [5.8 本地演示网站无法被评委直接访问](#)
- [6. 作品特征描述](#)
 - [6.1 源码证据链优先](#)
 - [6.2 七维 OS 机制画像](#)
 - [6.3 分层历史样本库](#)
 - [6.4 可控 LLM 增强](#)
 - [6.5 HTML 证据报告和 query-evidence 检索](#)
 - [6.6 本地优先和可复现交付](#)
- [7. 分工和协作](#)
 - [7.1 团队信息](#)
 - [7.2 工作分工](#)
 - [7.3 协作流程](#)
 - [7.4 质量协作方式](#)
- [8. 提交仓库目录和文件描述](#)
 - [8.1 核心目录](#)
 - [8.2 数据和报告目录](#)
 - [8.3 文档和演示目录](#)
 - [8.4 网站与公开展示目录](#)
 - [8.5 未直接提交的大体积本地数据](#)
- [9. 比赛收获](#)
 - [9.1 对操作系统作品分析的理解](#)
 - [9.2 对智能体工程边界的理解](#)
 - [9.3 对工程交付的理解](#)
 - [9.4 对后续改进方向的认识](#)

1. 比赛准备和调研

1.1 项目目标描述

KernelSage 的目标是设计并实现一套面向小型操作系统仓库的分析比对智能体。系统接收一个 OS 源码仓库后，自动扫描代码结构，抽取 OS 机制证据，生成结构化画像，并与历史比赛作品、教学内核和架构参考项目进行对比，最终输出人类可读、证据可复核的描述报告和比较报告。

项目目标可以拆成六项：

1. 构建仓库静态分析能力：读取源码、README、文档、构建脚本和目录结构，识别语言分布、核心文件和项目形态。
2. 构建 OS 机制画像：围绕启动、内存、调度、系统调用、文件系统、中断、驱动、同步等机制形成结构化判断。
3. 建立历史样本基线库：将可本地复核的历史作品、教学基线和参考项目纳入 manifest 管理，并为每个样本独立构建画像。
4. 生成证据链报告：报告中的关键结论尽量绑定源码路径、行号、代码片段和符号，便于评委回到仓库人工复核。
5. 支持受控 LLM 增强：LLM 只作为可选文本增强组件，不能绕过证据链直接裁定创新、重复或抄袭。
6. 完成可演示交付：提供命令行、报告样例、公开网站、操作手册和设计文档，满足初赛开源仓库审查和视频演示要求。

1.2 赛题理解与评审场景

赛题的核心不是重新实现一个操作系统，而是构建一个能够分析小型 OS 仓库、描述其技术特征、并与历史作品进行比较的智能体系统。对评委而言，系统需要回答三个问题：

- 输入仓库实现了哪些 OS 机制，证据在哪里；
- 它与哪些历史作品或教学基线相近，相近的依据是什么；
- 哪些内容属于合理的技术路线共性，哪些线索需要人工进一步复核。

因此，本项目把“证据优先、边界清晰、可复核”作为设计底线。KernelSage 不直接替代评委做最终裁决，也不把相似线索写成抄袭结论，而是将仓库画像、历史样本、相似证据和风险提示整理成可检查材料。

1.3 历史样本与开源资料调研

项目调研了往届操作系统比赛作品、教学内核、架构参考项目和赛事组提供的 collected-data 样本。现有历史基线库坚持本地可复现原则，只把能够成功 clone 或已经验证可用的仓库纳入正式样本清单。

当前样本库共包含 141 个历史样本，其中包括已验证代表作品、教学基线、架构参考项目，以及从赛事组 collected-data 中成功拉取的 120 个历史作品。赛事组 collected-data 原始记录为 168 条，其中 48 条因为仓库不可访问、认证限制、地址失效或网络拉取失败等原因未纳入正式本地基线库，并在导入说明中保留失败记录，避免在演示和评审中混淆样本来源。

这些样本不是合并成一个“大仓库”做文本查重，而是逐个仓库构建画像。后续输入比赛作品时，系统会根据架构、语言、规模、OS 机制覆盖度和功能相似度选择相近历史样本进行 Top N 对比。

1.4 相关技术调研与路线取舍

围绕赛题，本项目重点调研并取舍了四类技术路线：

方向	可用能力	取舍结果
传统关键词搜索	实现简单，适合快速定位文件和片段	单独使用容易误判，因此只作为证据候选来源之一
AST/符号解析	能识别函数、结构体、宏、模块等代码结构	当前采用轻量解析，覆盖 Rust/C/C++/Assembly，暂不做完整跨文件调用图
通用代码查重	能发现文本或 token 相似片段	与 OS 机制画像结合使用，避免把领域共性直接当成重复
LLM 报告生成	适合组织复杂信息和生成自然语言	只做可选增强，必须受证据、缓存、审计和失败回退约束

最终路线是“静态仓库分析 + OS 语义画像 + 历史样本检索 + 代码级相似线索 + 可选 LLM 增强”。这种路线兼顾可运行、可解释和可演示，适合初赛阶段的开源仓库审查。

2. 系统框架和模块设计

2.1 总体架构

KernelSage 按分层方式设计，整体数据流如下：



这种分层参考了成熟技术文档常用的“目标、框架、计划、进展、测试、问题、交付”组织方式，但具体模块完全围绕本项目的 OS 仓库分析比对场景设计。

2.2 入口与任务调度层

入口层主要由 `scripts/kernelsage.py` 和 `src/os_agent/cli.py` 组成，负责把用户命令转换为具体任务。主要命令包括：

命令	功能
<code>profile</code>	为单个仓库生成结构化画像
<code>describe</code>	生成单仓库描述报告，可选 HTML 和 LLM
<code>compare</code>	将输入仓库与历史样本库进行 Top N 对比
<code>describe-all</code>	批量生成历史样本描述结果
<code>manifest-audit</code>	检查样本库来源、repo_id、安全边界和本地完整性
<code>query-evidence</code>	根据“调度器/页表/系统调用”等概念检索源码证据
<code>audit-llm-report</code>	审计 LLM 生成报告是否越界引用或过度断言

入口层的设计原则是显式开关。默认命令不调用在线模型，不访问网络；只有用户显式传入 `--use-llm` 或执行拉取样本命令时，才会触发外部资源。

2.3 数据采集与仓库画像层

`collector.py` 负责扫描仓库文件、README、文档、构建脚本和 manifest 元数据，形成 `RepoSnapshot`。采集时会过滤常见低价值目录，避免把构建产物、依赖目录或缓存目录误当成核心实现。

`parser.py` 负责从 Rust、C、C++ 和 Assembly 文件中抽取函数、结构体、类、宏、模块声明和汇编符号。小型 OS 仓库经常混合多种语言，尤其是启动、trap、驱动和平台适配代码中常见 C/ASM 混合，因此符号抽取不能只面向单一语言。

`analyzer.py` 将采集结果转换为 `kernelProfile`。画像围绕 OS 机制组织，核心判断包括：

维度	典型证据
启动与引导	boot、entry、linker script、trap vector、platform init
内存管理	page table、allocator、mmap、frame、heap、VM area
任务调度	task、process、thread、scheduler、context switch
系统调用	syscall table、trap dispatch、用户态入口、兼容层
文件系统	inode、block、vfs、fat、fs driver、buffer cache
中断与异常	interrupt、trap、irq、PLIC、IDT、exception handler
驱动与设备	UART、virtio、block、console、timer、network、platform device
同步机制	spinlock、mutex、semaphore、atomic、wait queue

2.4 历史样本选择与相似线索层

历史对比层由 `selector.py`、`agent.py` 和相似线索逻辑组成。系统不会按目录顺序随意选取历史样本，而是综合以下因素排序：

- 项目风格是否接近，例如 `teaching-monolithic`、`microkernel`、`RTOS`、`unikernel`；
- 架构是否接近，例如 `RISC-V`、`x86`、`AArch64` 或多架构；
- 语言构成是否接近，例如 `Rust/C/C++/Assembly` 占比；
- OS 机制覆盖度是否接近；
- 代码规模和目录结构是否接近；
- 样本来源是否可信，是否有明确 `manifest` 记录。

相似线索分为两层：功能相似和代码级相似。功能相似说明两个 OS 项目解决的问题或机制相近；代码级相似进一步检查路径、函数或符号、结构体/类型、宏和局部片段 token/结构相似度。报告会明确这些线索只是人工复核入口，不是自动裁定。

2.5 LLM 增强、报告审计与回退层

`llm.py` 提供 DeepSeek/OpenAI-compatible API 调用能力，`llm_audit.py` 负责审计 LLM 输出。系统默认使用规则版报告，不消耗在线 API；启用 LLM 时，prompt 会包含已经抽取的证据、历史样本选择理由和边界要求。

为了避免幻觉，系统设置了四道约束：

1. 显式调用：必须使用 `--use-llm` 才会请求在线模型。
2. Dry-run：`--llm-dry-run` 只生成 prompt，不调用 API。
3. 缓存：LLM 响应按 prompt hash 缓存，避免重复扣费。
4. 审计与回退：报告引用未知文件、缺失核验摘要或越界确认创新点时，自动回退规则报告。

2.6 网站展示与部署层

网站部分位于 `site/`，通过静态页面展示项目介绍、历史基线库、报告样例和操作入口说明。
`scripts/build_site.py` 根据当前数据生成网站页面，`scripts/serve_site.py` 用于本地预览。

由于初赛要求提供可访问的网站链接，项目已将静态网站部署到阿里云 ECS，并通过 Nginx 暴露公网访问：

- 项目首页：`http://47.114.95.237/`
- 历史基线库页面：`http://47.114.95.237/baseline.html`

静态网站的价值在于降低评委查看门槛。评委不需要在本地安装 Python，也能先通过网页了解项目目标、样本库和演示材料。

2.7 核心数据结构与模块映射

数据结构 / 模块	责任	主要产出
<code>RepoSnapshot</code>	仓库扫描结果，包含文件、语言、README、构建入口	输入给解析器和分析器
<code>SymbolDef</code>	轻量符号定义，记录名称、类型、路径和行号	支撑 OS 机制识别和相似线索

数据结构 / 模块	责任	主要产出
<code>KernelProfile</code>	单个仓库的 OS 画像	描述报告、历史选择、比较报告
<code>Evidence</code>	证据文件、行号、片段和解释	报告证据链和 self-check
<code>CompareResult</code>	输入仓库与历史样本的比较结果	相似点、差异点、代码级线索
<code>ProfileCache</code>	本地画像缓存	加速 141 个历史样本复用
<code>ManifestAuditor</code>	样本库可信度检查	发现 repo_id、来源、奖项和本地路径问题

3. 开发计划

3.1 阶段一：MVP 仓库分析闭环

第一阶段目标是形成可运行的最小闭环：仓库采集、结构化画像、描述报告和基础比较报告。该阶段优先保证系统能对一个本地 OS 仓库产生稳定输出。

验收标准：

- 能扫描源码、README、docs 和构建入口；
- 能识别 Rust/C/Assembly 的基础符号，后续扩展 C++；
- 能生成 `kernelProfile`；
- 能输出 Markdown 描述报告；
- 能选择少量历史样本并生成对比报告。

3.2 阶段二：LLM 可控接入和证据核验

第二阶段目标是接入 LLM，但不让 LLM 成为不受控的裁判。系统需要支持 `.env` 本地配置、dry-run、缓存、失败回退和报告审计。

验收标准：

- 默认命令不调用在线模型；
- `.env` 和 `data/llm_cache/` 不进入仓库；
- `describe` 和 `compare` 均支持 LLM dry-run；
- 报告生成后有 self-check 核验摘要；
- LLM 失败或审计不通过时仍能输出规则版报告。

3.3 阶段三：历史样本选择和代码相似线索

第三阶段目标是提升比较报告质量。系统需要避免按目录顺序选样本，改为根据画像相似度选择更合理的历史基线。

验收标准：

- `selector.py` 根据风格、架构、语言、维度和规模评分；
- `compare` 报告展示历史样本选择理由；
- 代码级相似线索覆盖路径、符号、结构体/类型、宏和片段结构；

- 报告明确说明相似线索不等于抄袭裁定。

3.4 阶段四：样本扩展、网站发布和提交材料收敛

第四阶段围绕初赛交付展开。重点任务包括导入 collected-data、构建 141 个样本画像缓存、更新网站基线库、整理操作手册、固定演示案例和补齐设计技术文档。

验收标准：

- data/samples/manifest.json 记录 141 个可复核样本；
- docs/COLLECTED_DATA_IMPORT.md 记录 168 条原始数据中的成功和失败情况；
- 网站公开访问并展示最新基线库；
- README、操作手册、设计文档和报告样例互相指向；
- GitLab 和 GitHub 远端保持同步。

3.5 风险与回退计划

风险	回退方案
LLM API 不可用或余额不足	使用规则版报告，LLM 只作为可选增强
历史样本仓库无法访问	只纳入成功 clone 的样本，失败项写入导入说明
关键词误判 OS 机制	通过路径 token、符号过滤、低优先级目录过滤和人工抽查规则收敛
大样本库分析耗时	预构建 ProfileCache，后续输入仓库只读取历史画像缓存
公网网站无法访问	静态网站可本地预览，必要时重新部署 Nginx 目录
相似线索被误解为裁定	报告、README 和设计文档都保留人工复核边界

4. 比赛过程中的重要进展

4.1 阶段时间线

时间	关键进展	验证或产出
2026-05-29	完成 MVP 仓库分析闭环	collector/parser/analyzer/reporter/agent/cli 主流程跑通
2026-05-29	接入 LLM 客户端基础设施	支持 .env、--use-llm、--llm-dry-run、缓存和失败回退
2026-06-05	完成 demo 命令和 self-check	报告末尾加入证据核验摘要
2026-06-06	优化历史样本选择策略	selector.py 不再按目录顺序截断历史仓库
2026-06-11	完成报告人工抽查规则收口	修正 C++ 覆盖、宏注释误判、路径子串误判和 syscall stub 过度解读

时间	关键进展	验证或产出
2026-06 中旬	固定展示案例和 golden 校准样例	<code>xv6-public</code> 描述样例和 <code>oskerne12024-aabcb</code> 对比样例
2026-06 下旬	导入 collected-data 并扩展基线库	141 个历史样本，120 个来自赛事组 collected-data 成功 clone 项
2026-06 下旬	部署公开网站并整 理提交文档	网站、操作手册、设计技术文档、报告样例和 README 形成 闭环

4.2 从单仓库分析扩展为历史作品比对

项目早期重点是单仓库描述，后来扩展为“输入作品 vs 历史样本库”的比较模式。这样报告不只说明当前仓库内部实现情况，还能把它放到往届作品、教学基线和架构参考项目中横向定位。

以 `oskerne12024-aabcb` 这类输入作品为例，系统会先为输入仓库构建画像，再与历史样本库中相近项目进行对比，输出相似点、差异点、代码级线索和人工复核建议。

4.3 从 Top 3 对比扩展到 Top 5 对比

为了让比较结果更充分，系统将历史样本对比数量从 Top 3 扩展到 Top 5。这样可以减少偶然样本对结论的影响，让报告覆盖更多相近实现路线。

同时系统明确 API 消耗边界：如果只使用本地静态分析和已经构建好的画像缓存，Top 5 不会增加 LLM API 消耗；只有显式启用 LLM，并要求 LLM 分析更多历史样本时，token 消耗才会增加。

4.4 历史基线库扩展到 141 个样本

项目将赛事组提供的 collected-data 纳入历史基线建设。原始 collected-data 包含 168 条记录，成功拉取并整理进样本库的为 120 条，结合此前已验证样本后，正式历史基线库达到 141 个本地可用样本。

这些样本统一归类为“赛事历史作品”等可解释来源，不再把赛事组 collected-data 单独标成难以理解的内部类别。系统还为全部 141 个样本构建画像缓存，后续输入新作品时可以直接复用历史画像。

4.5 建立可公开访问的网站

本地 `http://localhost:8080/` 只能在开发机器访问，无法满足评委远程查看要求。因此项目将静态网站部署到阿里云 ECS，通过公网 IP 提供访问。

当前网站包含项目首页、历史基线库页面和相关展示内容，基线库页面能够反映最新的 141 个历史样本。该部署方式降低了评委访问门槛，也使演示视频中的链接与实际提交材料保持一致。

4.6 系统测试和质量验证

项目把测试和人工抽查作为质量闭环，而不是只依赖一次性手工检查。当前验证包括：

验证项	当前状态	说明
单元测试	92 个 unittest 通过	覆盖 CLI、报告生成、LLM 审计、fetch、self-check、HTML 和检索
语法检查	<code>compileall</code> 通过	检查 <code>src/</code> 、脚本和测试文件语法完整性

验证项	当前状态	说明
样本库审计	manifest-audit 可运行	检查 repo_id 安全、来源、奖项、本地目录和 HEAD 信息
报告人工抽查	已完成关键样本抽查	覆盖 FreeRTOS、seL4、IncludeOS、oskernel2024-aabcb 和对比报告
Golden 校准	已固定 2 份 golden	校准描述报告和比较报告的证据强度与边界表达

通过这些验证，系统把“报告是否可信”拆成可执行检查：证据文件是否存在、行号是否有效、历史样本是否可追溯、LLM 是否越界、相似线索是否保留人工复核边界。

5. 遇到的主要问题和解决方法

5.1 历史仓库来源复杂，部分仓库无法 clone

问题表现：赛事组 collected-data 中的仓库地址来源复杂，存在仓库删除、权限限制、地址变更、网络访问失败等情况。如果把所有原始记录都直接写入样本库，会造成后续演示时无法复现，也会影响评委对基线库可信度的判断。

解决方法：项目只把成功 clone 并能在本地检查的仓库纳入正式样本 manifest。对 168 条原始记录逐条尝试拉取，最终纳入 120 条可用样本，失败的 48 条保留在导入说明中，作为不可用记录而不是伪装成已验证样本。

实际效果：历史基线库保持 141 个可本地复核样本，网站和 manifest 展示的样本数量与本地事实一致。

5.2 样本来源分级不清，容易造成获奖信息误用

问题表现：历史样本可能来自获奖项目、普通赛事项目、教学内核或架构参考。如果在报告中不区分来源，容易把普通样本误写成获奖样本，或者把教学项目当作赛事作品评价。

解决方法：manifest 中维护样本类别、来源层级、奖项信息和来源链接。只有经过验证的项目才写入明确奖项信息；赛事组 collected-data 中后续补充的样本统一归入赛事历史作品，不使用未经确认的获奖表述。

实际效果：报告生成时按样本元数据展示来源，降低过度宣传和事实错误风险，也能回答评委“比对库有哪些、来源是什么”的问题。

5.3 关键字匹配容易误判 OS 机制

问题表现：早期规则容易因为文件名、宏名或普通注释命中关键词而误判。例如 `sys` 可能只是普通变量或路径片段，不一定代表系统调用；宏或配置项也可能只是占位，不代表完整机制实现。

解决方法：分析器改为结合路径、符号、文件类型、上下文和低价值目录过滤进行判断。对宏注释、构建产物、第三方目录和弱关键词降低权重；对启动入口、trap/interrupt 处理、页表、调度器、系统调用分发表等更强证据提高权重。

实际效果：报告不再只是关键词列表，而是更接近真实 OS 实现。报告人工抽查中发现的噪声规则已经固化到 parser、analyzer 和 self-check 流程中。

5.4 C++、unikernel、RTOS 等非典型内核覆盖不足

问题表现：小型 OS 项目不一定是 Rust 或 C 教学内核，也可能是 C++ 内核、unikernel、RTOS 或应用内核混合形态。若只支持少数扩展名和传统模块命名，容易漏掉真实实现。

解决方法：解析器扩展支持 `.cc`、`.cpp`、`.cxx`、`.hh`、`.hpp`、`.hxx` 等 C++ 文件，并在机制判断上允许不同项目形态有不同证据组合。系统不要求每个仓库都必须具备完整宏内核结构，而是根据项目定位解释其启动、内存、任务、驱动或运行时机制。

实际效果：IncludeOS 等 C++/unikernel 样本的文件系统、驱动和内存证据可以落到真实源码路径，RTOS 样本也能以更保守方式表达机制边界。

5.5 功能重合和代码相似边界不清

问题表现：操作系统作品天然会出现相似目录名和模块名，如 `memory`、`trap`、`syscall`、`fs`、`scheduler`。如果只看功能重合，容易把正常领域共性误解为代码重复；如果完全不看代码线索，又无法支撑查重辅助场景。

解决方法：系统把“功能相似”和“代码级相似线索”拆开表达。功能相似用于说明两个项目解决的问题相近；代码级线索进一步检查路径、函数名、类型名、宏、常量和局部片段结构。

实际效果：比较报告会明确这些线索是辅助判断依据，不直接等同于抄袭裁定。最终判断仍需要结合提交历史、说明文档、完整源码和人工复核。

5.6 LLM 输出存在幻觉和越界判断风险

问题表现：LLM 擅长组织语言，但如果不受约束，可能编造文件、误引历史样本、给出超出证据范围的判断，甚至把系统不能证明的内容写成确定结论。

解决方法：项目把 LLM 设计为可选增强层，不作为唯一分析来源。提示词要求模型基于已有证据表达；报告生成后使用审计工具检查未知引用、缺失章节和过度断言。没有启用 LLM 时，系统仍可生成规则化报告。

实际效果：LLM API 异常、JSON 异常、字段缺失或审计失败时，系统自动回退规则版报告，保证演示和评审材料不会被在线模型状态阻断。

5.7 大样本库重复分析耗时

问题表现：历史基线库扩展到 141 个样本后，如果每次输入比赛作品都重新扫描全部历史仓库，会显著增加演示时间，也会影响批量分析 200 份比赛仓库时的效率。

解决方法：系统为历史样本建立 `ProfileCache`。已经构建过的历史样本画像会缓存到本地，后续分析输入作品时只需要读取缓存并计算相似度。只有样本文件发生变化或缓存被清理时才需要重建。

实际效果：当前 141 个历史样本画像已全部构建完成。后续输入新仓库时，主要成本集中在新仓库扫描和相似度计算，不会重复读取每个历史仓库的全部源码。

5.8 本地演示网站无法被评委直接访问

问题表现：开发阶段网站运行在 `localhost:8080`，只能本机访问。初赛要求提交可访问的网站链接，评委无法通过本地地址查看内容。

解决方法：项目将静态站点部署到阿里云 ECS，并使用 Nginx 提供公网访问。网站内容来自仓库中的 `site/` 目录和构建脚本，包含项目说明、历史基线库和演示材料。

实际效果：评委点击公开链接即可查看页面，不需要本地运行项目。网站内容与仓库提交材料保持一致，适合放入 README、演示视频和提交表单。

6. 作品特征描述

6.1 源码证据链优先

KernelSage 的核心特征是先建立源码证据链，再生成自然语言报告。系统不仅输出“实现了调度、内存、系统调用”等结论，还会给出对应源码路径、行号、代码片段和相关符号。

这种设计适合操作系统比赛评审。评委可以沿着报告中的路径回到仓库源码，检查结论是否成立；参赛团队也可以据此发现文档缺口、实现短板和演示重点。

6.2 七维 OS 机制画像

系统按 OS 领域机制分析项目，而不是只统计代码量、语言和目录。七维画像覆盖调度、内存、系统调用、文件系统、中断、驱动、同步，并结合启动入口、构建脚本和项目风格进行解释。

这种画像方式能更贴近赛题本身。例如，对于 xv6/rCore 类教学内核，报告会重点关注进程、页表、trap、syscall 和文件系统；对于 RTOS，报告会关注任务调度、中断、同步和平台移植层；对于 unikernel，则会关注运行时、驱动、网络和应用一体化边界。

6.3 分层历史样本库

系统维护独立的历史样本 manifest 和画像缓存。每个历史样本都有自己的来源、类别、仓库地址和本地路径，不会把所有仓库混成一个不可解释的数据池。

当前参考库包含 141 个本地可复核样本，覆盖教学基线、赛事历史作品、比赛作品、RTOS、微内核、unikernel、不同语言和架构路线，并补入已核验代表案例。输入新作品时，系统根据画像相似度选择 Top 5 历史样本，输出相似点、差异点和代码级线索。

6.4 可控 LLM 增强

LLM 在本项目中承担辅助写作和对比表达工作。系统通过证据输入、提示词约束、dry-run、缓存、报告审计和失败回退控制 LLM 风险。

这种设计避免了两类极端：完全不用 LLM 会导致报告表达生硬、人工整理成本高；完全依赖 LLM 会导致报告不可复核。KernelSage 选择让静态分析提供事实基础，让 LLM 在边界内提升可读性。

6.5 HTML 证据报告和 query-evidence 检索

Markdown 报告之外，系统支持生成静态 HTML 证据报告，展示结论、证据文件、行号、自检状态和相似度分数。HTML 报告适合放入网站或演示材料，降低评委查看成本。

`query-evidence` 提供概念检索入口。用户输入“调度器/页表/系统调用”等中文或英文概念后，系统会返回相关源码位置、片段和匹配词。该功能适合演示“系统不是只会输出报告，也能反向定位证据”。

6.6 本地优先和可复现交付

核心能力可以本地运行，不依赖在线模型和外部网络。`profile`、`describe`、`compare`、`manifest-audit`、`query-evidence` 均可在本地执行；LLM 是可选增强，不影响规则版主流程。

提交材料上，项目用 README 做总入口，用操作手册支撑演示，用设计技术文档说明架构和过程，用报告样例展示输出效果，用网站提供公开访问页面。这些材料共同形成初赛交付闭环。

7. 分工和协作

7.1 团队信息

团队名称为“一定要以人类的身份赢啊”，成员为鲍灿辉、石雅禛，学校为天津师范大学。项目围绕面向小型操作系统的分析比对智能体展开，目标是在初赛阶段提交可运行代码、可访问网站、演示视频和配套文档。

7.2 工作分工

成员	主要职责	具体工作
鲍灿辉	智能体流程设计、代码分析模块、检索与比对实现、演示链路整理	仓库画像、历史样本对比、LLM 调用边界、ECS 部署、操作手册和提交材料检查
石雅禛	数据整理、报告模板、测试用例、文档撰写	初赛章节结构核对、比赛过程材料整理、报告可读性检查、操作流程整理

以上分工根据当前仓库已有记录和提交材料整理，后续可根据实际提交表格进一步细化。

7.3 协作流程

项目协作以 Git 仓库为中心，代码、文档、样本 manifest、报告样例和网站文件统一维护。开发流程大致为：需求拆解、模块实现、本地测试、报告抽查、文档更新、网站预览、提交推送。

文档协作遵循“README 负责快速入口，专项文档负责细节说明”的原则。README 用于评委快速了解项目和运行方式；设计技术文档、操作手册、样本导入说明、报告审计说明分别支撑不同审查场景。

7.4 质量协作方式

质量检查主要通过三类方式完成：

- 自动测试：运行 unittest、compileall、manifest-audit 等命令，检查基础功能和样本库可信度；
- 人工抽查：对 FreeRTOS、seL4、IncludeOS、oskernel2024-aabcb 等关键样本进行报告核验；
- 文档对照：对 README、操作手册、网站、设计文档和报告样例进行一致性检查，避免数量、链接或术语不一致。

8. 提交仓库目录和文件描述

8.1 核心目录

路径	说明
<code>src/os_agent/</code>	核心 Python 包，包含仓库采集、符号解析、画像分析、历史样本选择、报告生成、LLM 调用和审计逻辑。
<code>scripts/kernel sage.py</code>	主要命令行入口，用于分析输入仓库、生成报告、执行对比和审计。
<code>scripts/ fetch_repos.py</code>	批量拉取样本仓库的辅助脚本，用于建设历史基线库。
<code>scripts/ build_site.py</code>	根据当前数据和报告生成静态网站内容。

路径	说明
<code>scripts/serve_site.py</code>	本地预览静态网站的辅助脚本。
<code>tests/</code>	单元测试目录，覆盖分析、报告、样本审计、LLM 审计和网站数据等关键逻辑。

8.2 数据和报告目录

路径	说明
<code>data/samples/manifest.json</code>	历史样本清单，记录样本 ID、名称、来源、类别、仓库地址和本地路径等信息。
<code>data/reports/</code>	生成的分析报告和对比报告，作为演示和评审材料的一部分。
<code>data/samples/</code>	本地历史样本仓库目录。大体积仓库内容通常不直接提交，正式提交以 manifest 和说明文档为准。
<code>data/profiles/</code>	历史样本画像缓存目录，用于减少重复分析耗时。该目录属于本地生成数据。
<code>data/llm_cache/</code>	LLM 调用缓存目录，用于控制重复调用和 API 消耗。

8.3 文档和演示目录

路径	说明
<code>README.md</code>	项目总入口，说明项目定位、快速运行方式、样本库和网站链接。
<code>BEGINNER_OPERATION_MANUAL1.md</code>	面向演示和初学者的操作手册，说明如何运行网站、分析输入仓库和查看报告。
<code>docs/design.md</code>	系统设计说明，记录核心架构和模块职责。
<code>docs/PLAN.md</code>	开发计划和阶段目标。
<code>docs/HIGHLIGHTS.md</code>	项目亮点、痛点和解决方案材料。
<code>docs/REPORT_AUDIT.md</code>	报告质量检查和审计说明。
<code>docs/CODE_SIMILARITY_SOLUTION.md</code>	代码相似线索设计说明。
<code>docs/COLLECTED_DATA_IMPORT.md</code>	赛事组 collected-data 导入结果，记录成功样本和失败原因。
<code>docs/DESIGN_TECHNICAL_DOCUMENT.md</code>	本设计技术文档，对初赛要求的 9 个章节进行集中整理。

8.4 网站与公开展示目录

路径	说明
<code>site/index.html</code>	项目公开网站首页。
<code>site/baseline.html</code>	历史基线库页面，展示 141 个历史样本。
<code>site/reports/</code>	静态报告展示内容。
<code>site/assets/</code>	网站样式和静态资源。

公开访问入口为 `http://47.114.95.237/`。评委可通过该链接查看项目网站，通过 `baseline.html` 查看历史基线库。

8.5 未直接提交的大体积本地数据

历史样本仓库、画像缓存和 LLM 缓存可能包含大量第三方代码或生成数据，不适合全部提交到比赛仓库。项目采用 manifest、导入说明、报告样例和网站页面说明样本来源和使用方式。

对于评委关心的“比对库是哪些”，仓库通过 `data/samples/manifest.json`、`docs/COLLECTED_DATA_IMPORT.md` 和网站基线库页面给出清单。对于需要复现的样本，可根据 manifest 中的仓库地址重新 clone，或在本地已有样本目录上直接运行分析。

9. 比赛收获

9.1 对操作系统作品分析的理解

通过项目建设，我们更清楚地认识到，小型操作系统作品不能只用代码量或关键词评价。启动流程、内存管理、调度、系统调用、文件系统、驱动和中断等机制之间存在关联，分析报告必须尽量说明证据来源和实现边界。

同时，不同作品可能选择不同路线：有的偏教学内核，有的偏架构实验，有的偏驱动或运行时，有的偏 unikernel 或 RTOS。合理评价需要尊重项目定位，而不是套用单一模板。

9.2 对智能体工程边界的理解

本项目让我们认识到，LLM 适合帮助组织复杂信息，但不适合在没有证据的情况下直接做技术裁定。面向评审和查重辅助场景时，智能体必须有明确的输入、缓存、引用、审计和失败处理机制。

因此，KernelSage 把确定性分析放在前面，把 LLM 放在可控增强层，并通过报告审计减少幻觉。这种工程边界比单纯追求自然语言流畅更重要。

9.3 对工程交付的理解

比赛提交不是只提交代码，还需要 README、设计文档、操作手册、网站链接、报告样例和演示视频形成闭环。项目在后期补齐了公开网站、历史基线库说明、样本导入记录和技术设计文档，使评委能够从多个入口理解作品。

这次开发也强化了我们对于可复现性的理解：样本来源要可解释，报告结论要可检查，网站内容要能被外部访问，命令和文档要能支撑演示。只有这些环节同时成立，系统才真正具备比赛交付价值。

9.4 对后续改进方向的认识

当前系统已经能支撑初赛演示和开源仓库审查，但仍有继续提升空间。后续可以考虑引入更细粒度 AST、调用图、include/use 图、轻量 embedding 或 BM25 融合检索，以提升复杂仓库下的语义识别能力。

同时，历史样本库可以继续抽查和扩展，特别是对已核验获奖作品建立更严格的 golden 校准样例。对于 LLM 部分，可以继续压缩 prompt、优化 token 成本，并把报告审计规则接入更完整的 CI 流程。